


神经网络

原文：https://pytorch.org/tutorials/beginner/blitz/neural_networks_tutorial.html#sphx-glr-beginner-blitz-neural-networks-tutorial-py

可以使用 `torch.nn` 包构建神经网络。

现在您已经了解了 `autograd`，`nn` 依赖于 `autograd` 来定义模型并对其进行微分。`nn.Module` 包含层，以及返回 `output` 的方法 `forward(input)`。

例如，查看以下对数字图像进行分类的网络：



卷积网

这是一个简单的前馈网络。它获取输入，将其一层又一层地馈入，然后最终给出输出。

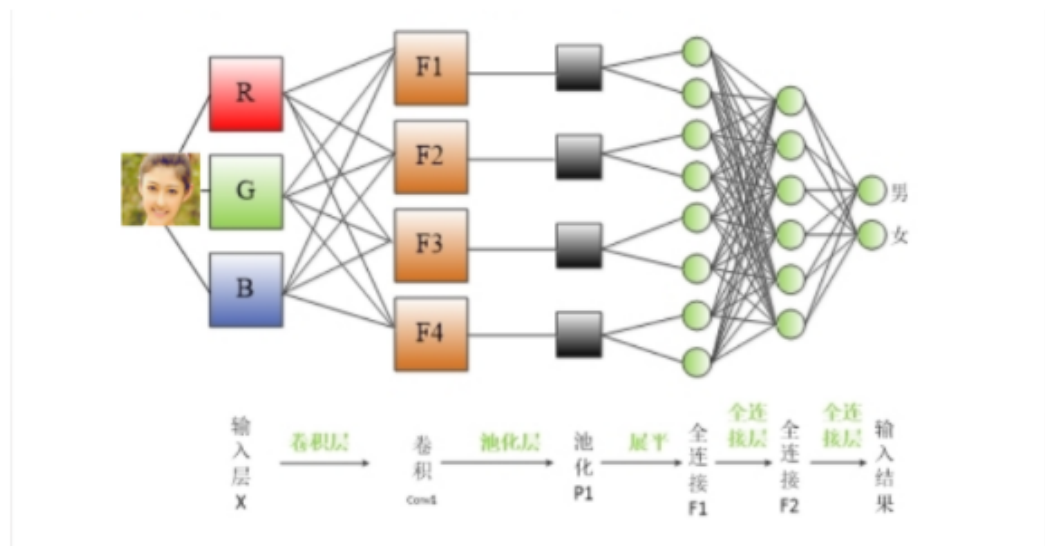
神经网络的典型训练过程如下：

- 定义具有一些可学习参数（或权重）的神经网络
- 遍历输入数据集
- 通过网络处理输入1c
- 计算损失（输出正确的距离有多远）
- 将梯度传播回网络参数
- 通常使用简单的更新规则来更新网络的权重： $\text{weight} = \text{weight} - \text{learning_rate} * \text{gradient}$


依序分析神经元层次结构

神经元结构参考网址：

初识神经网络中的各种层和神经网络结构[ch206265的博客-CSDN博客](#)神经网络各个层
深入学习卷积神经网络中卷积层和池化层的意义 - 战争热诚 - 博客园
(cnblogs.com)




- 输入层：预处理输入(一般是整张图象),将输入数据去均值和归一化,再在各个维度上PCA和白化,降维形成若干不相关的特征轴
 - 取均值和归一化 类似于 将正态分布标准化为标准正态分布
 - PCA和白化 类似于 将多元分布展开为若干边缘分布,再进行归一化
- 卷积层：一种多输入和多结果的运算,但是结果个数与输入个数可以不同
 - 每个结果,与每个输入的不同的某个特定局部相关(局部感知):
 - F1可能以R的左上侧,G的右下侧,B的左上侧为卷积层的输入
 - F2可能以R的左下侧,G的右上侧,B的左下侧为卷积层的输入



- 激活层：非线性层,使输出控制在一定范围内,包括ReLU, tanh等函数
- 池化层：pooling层,在不同深度上欠采样(损失信息的采样),降低特征的维度,防止过拟合
- 输出层(全连接层):神经网络的最后一层,结构是线性层+softmax函数,视为多分类器
 - 线性层: linear层,满足 $y = x * A^T + b$,
 - softmax函数: 将K阶向量映射为新K阶向量,新K阶向量的各分量相当于各label的概率(权重),相当于是k个标签的分类器得出的各标签概率结果

- 一般在全连接层前可以进行神经元的dropout(删减)和局部归一化



定义网络

让我们定义这个网络:

```
1 import torch
2 import torch.nn as nn
3 import torch.nn.functional as F
4
5
6 class Net(nn.Module):
7
8     def __init__(self):
9         super(Net, self).__init__()
10        # 1 input image channel, 6 output channels, 5x5 square convolution
11        # kernel
12        self.conv1 = nn.Conv2d(1, 6, 5)
13        self.conv2 = nn.Conv2d(6, 16, 5)
14        # an affine operation(仿射变换):  $y = Wx + b$ 
15        self.fc1 = nn.Linear(16 * 5 * 5, 120) # 5*5 from image dimension
16        self.fc2 = nn.Linear(120, 84)
17        self.fc3 = nn.Linear(84, 10)
18
19    def forward(self, x):
20        # Max pooling over a (2, 2) window
21        x = F.max_pool2d(F.relu(self.conv1(x)), (2, 2))
22        # If the size is a square, you can specify with a single number
23        x = F.max_pool2d(F.relu(self.conv2(x)), 2)
24        x = torch.flatten(x, 1) # flatten all dimensions except the batch
dimension
25        x = F.relu(self.fc1(x))
26        x = F.relu(self.fc2(x))
27        x = self.fc3(x)
28        return x
```

```
29
30
31 net = Net()
32 print(net)
```

出:

```
1 Net(
2   (conv1): Conv2d(1, 6, kernel_size=(5, 5), stride=(1, 1))
3   (conv2): Conv2d(6, 16, kernel_size=(5, 5), stride=(1, 1))
4   (fc1): Linear(in_features=400, out_features=120, bias=True)
5   (fc2): Linear(in_features=120, out_features=84, bias=True)
6   (fc3): Linear(in_features=84, out_features=10, bias=True)
7 )
```

您只需要定义 `forward` 函数，就可以使用 `autograd` 为您自动定义 `backward` 函数（计算梯度）。您可以在 `forward` 函数中使用任何张量操作。

模型的可学习参数由 `net.parameters()` 返回

```
1 params = list(net.parameters())
2 print(len(params))
3 print(params[0].size()) # conv1's .weight
4
```

出:

```
1 10
2 torch.Size([6, 1, 5, 5])
3
```

让我们尝试一个 `32x32` 随机输入。注意：该网络的预期输入大小（LeNet）为 `32x32`。要在 MNIST 数据集上使用此网络，请将图像从数据集中调整为 `32x32`。

```
1 input = torch.randn(1, 1, 32, 32)
2 out = net(input)
3 print(out)
4
```

出:

```
1 tensor([[ 0.0818, -0.0857,  0.0695,  0.1430,  0.0191, -0.1402,  0.0499,
2          -0.0737,
3          -0.0857,  0.1395]], grad_fn=<AddmmBackward0>)
```

使用随机梯度将所有参数和反向传播的梯度缓冲区归零：

```
1 net.zero_grad()
2 out.backward(torch.randn(1, 10))
3
```

注意

`torch.nn` 仅支持小批量。 整个 `torch.nn` 包仅支持作为微型样本而不是单个样本的输入。

例如，`nn.Conv2d` 将采用 `nSamples x nChannels x Height x Width` 的 4D 张量。

如果您只有一个样本，只需使用 `input.unsqueeze(0)` 添加一个假批量尺寸。

在继续之前，让我们回顾一下到目前为止所看到的所有类。

回顾：

- `torch.Tensor` - 一个多维数组，支持诸如 `backward()` 的自动微分操作。 同样，保持相对于张量的梯度。
- `nn.Module` - 神经网络模块。 封装参数的便捷方法，并带有将其移动到 GPU，导出，加载等的帮助器。
- `nn.Parameter` - 一种张量，即将其分配为 `Module` 的属性时，自动注册为参数。
- `autograd.Function` - 实现自动微分操作的正向和反向定义。 每个 `Tensor` 操作都会创建至少一个 `Function` 节点，该节点连接到创建 `Tensor` 的函数，并且编码其历史记录。

目前为止，我们涵盖了：

- 定义神经网络
- 处理输入并向后调用

仍然剩下：

- 计算损失
- 更新网络的权重

损失函数

损失函数采用一对（输出，目标）输入，并计算一个值，该值估计输出与目标之间的距离。

`nn` 包下有几种不同的**损失函数**。 一个简单的损失是：`nn.MSELoss`，它计算输入和目标之间的均方误差。

例如：

```

1 output = net(input)
2 target = torch.randn(10) # a dummy target, for example
3 target = target.view(1, -1) # make it the same shape as output
4 criterion = nn.MSELoss()
5
6 loss = criterion(output, target)
7 print(loss)
8

```

出:

```

1 tensor(1.1649, grad_fn=<MseLossBackward0>)
2

```

现在, 如果使用 `.grad_fn` 属性向后跟随 `loss`, 您将看到一个计算图, 如下所示:

```

1 input -> conv2d -> relu -> maxpool2d -> conv2d -> relu -> maxpool2d
2       -> view -> linear -> relu -> linear -> relu -> linear
3       -> MSELoss
4       -> loss
5

```

因此, 当我们调用 `loss.backward()` 时, 整个图将被微分。损失, 并且图中具有 `requires_grad=True` 的所有张量将随梯度累积其 `.grad` 张量。

为了说明, 让我们向后走几步:

```

1 print(loss.grad_fn) # MSELoss
2 print(loss.grad_fn.next_functions[0][0]) # Linear
3 print(loss.grad_fn.next_functions[0][0].next_functions[0][0]) # ReLU
4

```

出:

```

1 <MseLossBackward0 object at 0x7f71283dd048>
2 <AddmmBackward0 object at 0x7f71283dd7f0>
3 <AccumulateGrad object at 0x7f71283dd7f0>
4

```

反向传播

要反向传播误差, 我们要做的只是对 `loss.backward()`。不过, 您需要清除现有的梯度, 否则梯度将累积到现有的梯度中。

现在，我们将其称为 `loss.backward()`，然后看一下向后前后 `conv1` 的偏差梯度。

```
1 net.zero_grad()      # zeroes the gradient buffers of all parameters
2
3 print('conv1.bias.grad before backward')
4 print(net.conv1.bias.grad)
5
6 loss.backward()
7
8 print('conv1.bias.grad after backward')
9 print(net.conv1.bias.grad)
10
```

出：

```
1 conv1.bias.grad before backward
2 tensor([0., 0., 0., 0., 0., 0.])
3 conv1.bias.grad after backward
4 tensor([ 0.0188,  0.0172, -0.0044, -0.0141, -0.0058, -0.0013])
5
```

现在，我们已经看到了如何使用损失函数。

稍后阅读：

神经网络包包含各种模块和损失函数，这些模块和损失函数构成了深度神经网络的构建块。 带有文档的完整列表位于此处。

唯一需要学习的是：

- 更新网络的权重

更新权重

实践中使用的最简单的更新规则是随机梯度下降（SGD）：

```
weight = weight - learning_rate * gradient
```

我们可以使用简单的 Python 代码实现此目标：

```
1 learning_rate = 0.01
2 for f in net.parameters():
3     f.data.sub_(f.grad.data * learning_rate)
4
```

但是，在使用神经网络时，您希望使用各种不同的更新规则，例如 SGD, Nesterov-SGD, Adam, RMSProp 等。为实现此目的，我们构建了一个小包装：`torch.optim`，可实现所有这些方法。使用它非常简单：

```
1 import torch.optim as optim
2
3 # create your optimizer
4 optimizer = optim.SGD(net.parameters(), lr=0.01)
5
6 # in your training loop:
7 optimizer.zero_grad() # zero the gradient buffers
8 output = net(input)
9 loss = criterion(output, target)
10 loss.backward()
11 optimizer.step() # Does the update
12
```

注意

观察如何使用 `optimizer.zero_grad()` 将梯度缓冲区手动设置为零。这是因为如[反向传播](#)部分中所述累积了梯度。

脚本的总运行时间： (0 分钟 3.778 秒)

下载 Python 源码： `neural_networks_tutorial.py`

下载 Jupyter 笔记本： `neural_networks_tutorial.ipynb`

由 Sphinx 画廊生成的画廊